

LexData: Una plataforma de inteligencia predictiva para la duración de procesos judiciales de familia en el Valle del Cauca, Colombia

Luz Ángela Carabali Mulato²²³⁰⁶⁵²¹, Nicolás Zapata Obando²²³⁰³⁰³¹, and
Laura Daniela Astudillo²²³⁶³¹⁸¹

Universidad Autónoma de Occidente, Cali, Colombia

Abstract. El sistema judicial colombiano enfrenta una congestión severa: más de 2 millones de casos se radican cada año y los tiempos de resolución pueden superar los 10 años. El nicho de derecho de familia – violencia intrafamiliar (VIF), cuotas alimentarias y disputas de custodia – concentra una parte significativa de este rezago, en particular en el Valle del Cauca. Presentamos LexData, una plataforma de inteligencia predictiva que estima la duración de los procesos, identifica factores de riesgo de demora y ofrece un tablero interactivo para operadores judiciales. El sistema integra seis fuentes de datos gubernamentales abiertas mediante la API Socrata, calcula un Índice de Vulnerabilidad Familiar (IVF) compuesto para 42 municipios y entrena un regresor XGBoost sobre 5,000 registros sintéticos. El modelo alcanza un R^2 de 0.869 y un MAPE de 16.0%, con el estado de apelación (44.7%) y el número de audiencias (42.3%) como predictores dominantes de la duración. Un sistema de alertas tempranas clasifica el 22.8% de los casos como de riesgo medio o alto de retraso. Incluimos análisis de supervivencia (Kaplan-Meier y Cox PH) para modelar la probabilidad de resolución en el tiempo. El tablero en Streamlit permite a jueces, abogados y administradores explorar predicciones, visualizar índices de vulnerabilidad geográficamente y priorizar cargas de trabajo. Nuestros resultados demuestran que, incluso con datos sintéticos, el aprendizaje automático puede descubrir patrones procesables en la duración de procesos judiciales, abriendo camino hacia una gestión judicial basada en datos en contextos de recursos limitados.

Keywords: XGBoost · Predicción Judicial · Índice de Vulnerabilidad Familiar · Analítica Legal · Streamlit

1 Introducción

El sistema judicial colombiano tramita más de 2 millones de casos nuevos cada año, lo que lo convierte en uno de los más congestionados de América Latina [1]. El Consejo Superior de la Judicatura reporta que algunos procesos civiles y de familia tardan hasta una década en resolverse. Esta congestión no es uniforme: se concentra en regiones y tipos de despacho específicos, y los factores que la impulsan siguen siendo poco comprendidos porque no existe una herramienta analítica sistemática que correlacione los atributos de los casos con su duración.

El nicho de derecho de familia en el departamento del Valle del Cauca está particularmente tensionado. La violencia intrafamiliar (VIF), la inasistencia alimentaria, las disputas de custodia y las medidas de protección del ICBF conforman la mayor parte de las cargas procesales de los juzgados de familia [2]. Las comisarías de familia atienden más de 400,000 casos al año, y los defensores de familia del ICBF manejan entre 30 y 50 casos simultáneos en municipios con acceso limitado a tecnología [3].

Nuestra hipótesis central es que estos tipos de caso no son independientes. Proponemos un **Ciclo de Vulnerabilidad Familiar**: el consumo de sustancias desestabiliza los hogares, desencadenando episodios de violencia doméstica, que a su vez llevan a delitos contra la propiedad y, finalmente, a la ruptura familiar y las demandas de alimentos. Si este ciclo es medible, debería ser predictivo – es decir, el perfil de vulnerabilidad de un municipio puede ayudar a pronosticar cuánto tardarán en resolverse sus casos.

Construimos LexData para probar esta hipótesis y para ofrecer una herramienta práctica a los operadores judiciales. La plataforma tiene tres componentes:

1. Un **modelo predictivo** (regresor XGBoost) que estima la duración del proceso a partir de atributos del caso.
2. Un **sistema de alertas tempranas** que señala casos que exceden umbrales históricos de percentiles.
3. Un **tablero interactivo** (Streamlit) que visualiza predicciones, alertas y el Índice de Vulnerabilidad Familiar (IVF) geográficamente.

Este artículo describe la metodología, reporta los resultados experimentales y discute las limitaciones y direcciones futuras. Las contribuciones principales son: (1) un índice de vulnerabilidad compuesto adaptado al contexto del derecho de familia colombiano, (2) una comparativa de cuatro modelos de regresión sobre datos judiciales sintéticos, (3) la identificación del estado de apelación y el número de audiencias como predictores dominantes de la duración, y (4) un tablero de análisis judicial funcional y de código abierto.

2 Trabajos Relacionados

2.1 Aprendizaje Automático en Sistemas Judiciales

La aplicación del aprendizaje automático a la analítica legal ha crecido rápidamente. Chen y Guestrin [4] introdujeron XGBoost, que se convirtió en un estándar para tareas de predicción tabular, incluyendo resultados judiciales. Katz et al. [5] predijeron decisiones de la Corte Suprema de EE.UU. con más del 70% de precisión usando random forests. Más recientemente, [6] realizaron una encuesta de aplicaciones de ML en tribunales europeos, encontrando que la predicción de la duración de casos sigue siendo poco explorada en comparación con la predicción de resultados.

En América Latina, [7] aplicaron gradient boosting para predecir la duración de casos laborales en Brasil, alcanzando MAPE de aproximadamente 18%. [8]

utilizaron procesamiento de lenguaje natural en documentos judiciales colombianos para clasificar tipos de proceso. Hasta donde sabemos, ningún trabajo previo ha combinado índices de vulnerabilidad municipal con predicción a nivel de caso para juzgados de familia colombianos.

2.2 Índices de Vulnerabilidad y Predicción del Delito

Los índices de vulnerabilidad compuestos están bien establecidos en salud pública [9] y criminología [10]. El Índice de Criminalidad del FBI y el Índice de Privación Múltiple del Reino Unido son ejemplos de agregación de indicadores dispares en una puntuación única. [11] utilizaron variables socioeconómicas para predecir focos de criminalidad con gradient boosting. Nuestro IVF adapta este enfoque al dominio del derecho de familia, ponderando violencia intrafamiliar (40%), demandas de alimentos (30%), medidas de protección del ICBF (20%) e inasistencia alimentaria (10%).

2.3 Análisis de Supervivencia en Investigación Legal

Los modelos de riesgos proporcionales de Cox se han utilizado para estudiar tiempo-hasta-evento en contextos legales. [12] aplicaron análisis de supervivencia a decisiones de libertad condicional. [13] modelaron el tiempo hasta el juicio en tribunales federales de EE.UU. Nuestro trabajo extiende esto a los juzgados de familia colombianos, usando curvas de Kaplan-Meier para comparar tasas de resolución entre tipos de caso y niveles de IVF.

3 Metodología de Investigación

3.1 Pipeline de Datos

Construimos un pipeline ETL en Python que se conecta al portal de datos abiertos de Colombia (datos.gov.co) mediante la API Socrata. El pipeline se enfoca en seis conjuntos de datos:

Table 1: Fuentes de datos para LexData.

ID	Fuente	Descripción	Registros
1	INMLCF	Violencia intrafamiliar forense	5,856
2	Policía SIEDCO	Reportes VIF de policía	0*
3	Fiscalía	Inasistencia alimentaria	3**
4	Min. Justicia	Directorio de comisarías de familia	78
5	ICBF	Medidas de protección	67

ID	Fuente	Descripción	Registros
6	Generado	Registros sintéticos de ca- 5,000 sos	
*Sin resultados para el filtro Valle del Cauca. **Conjunto de respaldo.			

El pipeline incluye filtrado SOQL, reintento con retroceso exponencial y respaldo automático para conjuntos no disponibles. Las puntuaciones IVF se calculan por municipio usando:

$$IVF_m = 0.4 \cdot VIF_m^{\text{norm}} + 0.3 \cdot Alim_m^{\text{norm}} + 0.2 \cdot ICBF_m^{\text{norm}} + 0.1 \cdot Inasist_m^{\text{norm}} \quad (1)$$

Todos los componentes se normalizan por población municipal y se escalan a 0–100 para su interpretabilidad.

3.2 Entrenamiento del Modelo

Generamos 5,000 registros sintéticos de casos con atributos que imitan los datos de los juzgados de familia colombianos. Las características incluyen:

- **Nivel del caso:** tipo de proceso (VIF, alimentos, hurto patrimonial, sustancias), número de audiencias, indicador de apelación, año de radicación.
- **Municipal:** puntuación IVF.
- **Despacho:** identificador del juzgado, relación de carga (casos por juez).

La variable objetivo es la duración del caso en días. Usamos una división temporal de entrenamiento y prueba (2020–2023 entrenamiento, 2024 prueba) para simular la predicción en el mundo real. Se compararon cuatro modelos:

- Regresión Ridge (línea base)
- Random Forest (200 árboles, max_depth=8)
- Gradient Boosting (200 estimadores, lr=0.05)
- XGBoost (300 estimadores, lr=0.04, max_depth=5)

Los hiperparámetros se establecieron mediante exploración inicial; reservamos la opción de GridSearchCV para trabajo futuro.

3.3 Sistema de Alertas Tempranas

Definimos niveles de riesgo basados en umbrales de percentiles por tipo de proceso y despacho:

$$\text{Riesgo} = \begin{cases} \text{Alto,} & \text{si duración} > 1.5 \times P75 \\ \text{Medio,} & \text{si } P75 < \text{duración} \leq 1.5 \times P75 \\ \text{Bajo,} & \text{en otro caso} \end{cases} \quad (2)$$

3.4 Análisis de Supervivencia

Para el modelado de tiempo-hasta-evento, utilizamos la librería lifelines [14]. Las curvas de Kaplan-Meier estiman la probabilidad de que un caso permanezca activo en el tiempo, estratificadas por tipo de proceso y nivel de IVF. El modelo de riesgos proporcionales de Cox cuantifica los efectos de las covariables sobre el riesgo de resolución.

4 Caso Experimental

4.1 Área de Estudio

Nos enfocamos en 42 municipios del departamento del Valle del Cauca, el tercer departamento más poblado de Colombia y uno con alta congestión judicial. La región abarca centros urbanos (Cali, Palmira, Buenaventura) y zonas rurales con acceso limitado a tribunales.

4.2 Generación de Datos Sintéticos

Ante la falta de microdatos públicos del Consejo Superior de la Judicatura, generamos 5,000 registros sintéticos de casos. Las distribuciones de duración se calibraron con base en estadísticas judiciales publicadas:

- Duración media: 294 días (d.e. 120 días)
- Tasa de terminación: 84.6%
- Distribución por tipo: 35% alimentos, 35% VIF, 20% hurto patrimonial, 10% sustancias

Las puntuaciones IVF van de 33 (Zarzal) a 89 (Buenaventura), reflejando grandes disparidades en la vulnerabilidad familiar en todo el departamento.

4.3 Implementación


El pipeline ETL y el entrenamiento del modelo se ejecutan en cuadernos Jupyter. El tablero es una aplicación Streamlit (más de 600 líneas) con cinco secciones: Resumen General, Mapa IVF, Alertas Tempranas, Predictor de Duración y Análisis por Juzgado. El modelo entrenado se serializa con joblib y lo carga el tablero en tiempo de ejecución.

5 Discusión

5.1 Análisis Exploratorio

La Figura 5.1 presenta un análisis exploratorio de cuatro paneles. El panel (a) muestra la distribución de la duración por tipo de proceso: todos los tipos presentan distribuciones sesgadas a la derecha con modas entre 60 y 120 días, pero

los casos de HURTO_PATRIMONIAL tienen la cola más larga, superando los 600 días. Este sesgo sugiere que una minoría de casos complejos impulsa la duración promedio al alza. El panel (b) clasifica los municipios por duración media: Buenaventura, Cali y Palmira muestran consistentemente tiempos de procesamiento más largos, lo que se correlaciona con sus puntuaciones IVF más altas (89, 82 y 74 respectivamente). El panel (c) grafica la puntuación IVF frente a la duración del caso – la correlación de Pearson positiva pero moderada ($r \approx 0.28$) indica que la vulnerabilidad municipal explica parte, pero no la mayoría, de la varianza a nivel de caso individual. El panel (d) compara la duración entre juzgados: la variabilidad entre despachos es sustancial, con algunos juzgados mostrando medianas de duración 40% más altas que otros para los mismos tipos de caso, sugiriendo que la gestión del juzgado y la distribución de la carga laboral son factores significativos.



captionPanel EDA: (a) distribución de duración por tipo de proceso – nótese el sesgo derecho en todos los tipos; (b) principales municipios por duración media – Buenaventura lidera con IVF de 89; (c) dispersión IVF vs. duración con línea de tendencia – correlación positiva pero moderada ($r \approx 0.28$); (d) diagrama de caja de duración por juzgado – variabilidad sustancial entre despachos.

5.2 Rendimiento Predictivo

XGBoost superó a todos los demás modelos con un MAPE de 16.0% (MAE = 37 días, $R^2 = 0.869$). Esto está cerca de nuestro objetivo del 15%; la brecha probablemente se debe a la naturaleza sintética de los datos y al tamaño de muestra limitado. Se espera que los datos reales del CSJ mejoren la precisión.

La Figura 1 (panel izquierdo) grafica la duración predicha versus la real. Los puntos se agrupan a lo largo de la diagonal, lo que indica una buena calibración en todo el rango de duraciones. El modelo subestima ligeramente los casos muy largos (>500 días), lo cual es esperado dada su escasez en los datos de entrenamiento. El panel derecho muestra la distribución de errores: es aproximadamente normal con media cercana a cero ($\mu \approx 0$ días) y desviación estándar de 47 días. Aproximadamente el 68% de las predicciones caen dentro de ± 47 días del valor real, lo cual es razonable para fines de planificación judicial.




Fig. 1. Evaluación del modelo: duración predicha vs. real (izquierda) – los puntos siguen la diagonal con ligera subestimación en la cola superior; distribución de errores (derecha) – aproximadamente normal, centrada en cero con $\sigma = 47$ días.

5.3 Importancia de las Variables

La Figura 2 revela una concentración notable del poder predictivo en dos variables: el estado de apelación (44.7%) y el número de audiencias (42.3%), que juntas representan el 87% de la capacidad predictiva del modelo. Este hallazgo tiene implicaciones directas para las políticas: si los administradores judiciales pudieran identificar tempranamente los casos con probabilidad de apelación y canalizarlos hacia mecanismos alternativos de solución de conflictos, el impacto en la duración promedio sería sustancial. El efecto del número de audiencias es igualmente intuitivo – cada audiencia representa tiempo de programación, preparación y deliberación, por lo que los casos con más audiencias son inherentemente más largos.

Las variables restantes – tipo de proceso (5.4%), carga del despacho (3.9%), puntuación IVF (1.2%), municipio (0.9%), año de radicación (0.9%) e identidad del despacho (0.8%) – contribuyen relativamente poco a las predicciones individuales. Sin embargo, su valor agregado es estratégico: la puntuación IVF y los datos municipales permiten la asignación geográfica de recursos, mientras que las variables a nivel de despacho identifican cuellos de botella sistémicos.




Fig. 2. Importancia de variables clasificada por contribución relativa al modelo XG-Boost. La apelación y el número de audiencias dominan (87% combinadas). La puntuación IVF, el municipio y el juzgado contribuyen marginalmente a nivel de caso.

5.4 Alertas Tempranas

El sistema marcó 66 casos de alto riesgo (1.3%) y 1,073 casos de riesgo medio (21.5%). Los casos de alto riesgo se concentran en los juzgados con mayor carga procesal y en municipios con puntuaciones IVF elevadas. El sistema de alertas utiliza un umbral simple e interpretable (percentil 75 por tipo de proceso y despacho), lo que lo hace práctico para su implementación sin necesidad de formación especializada.

5.5 Análisis de Supervivencia

Las curvas de Kaplan-Meier (Fig. 3, izquierda) muestran la probabilidad de que un caso permanezca activo en el tiempo, estratificada por tipo de proceso. La separación entre curvas es estadísticamente significativa (prueba de log-rank, $p < 0.001$). Los casos de VIF se resuelven más rápido, con un 50% de probabilidad de resolución para el día 180; los casos de HURTO_PATRIMONIAL son los más lentos, alcanzando la marca del 50% solo después del día 280. El panel derecho de la Fig. 3 estratifica por nivel de IVF: los municipios con IVF alto (>70) muestran consistentemente una resolución más lenta en todo el horizonte temporal, confirmando que la vulnerabilidad familiar crea demoras estructurales que se agravan con el tiempo.

El modelo de Cox PH (concordancia = 0.874) cuantifica los efectos de las covariables sobre el riesgo de resolución. La Figura 4 muestra los hazard ratios: valores inferiores a 1 indican que la variable disminuye la tasa de resolución (es decir, prolonga el caso). Las puntuaciones IVF más altas reducen el riesgo de resolución en aproximadamente un 15% por aumento de una desviación estándar, manteniendo constantes las demás variables. Esto confirma que la vulnerabilidad municipal genera un lastre medible sobre la eficiencia judicial, independientemente del tipo de caso y las características del juzgado.




Fig. 3. Curvas de supervivencia de Kaplan-Meier: por tipo de proceso (izquierda) – VIF se resuelve más rápido, hurto patrimonial es el más lento; por nivel de IVF (derecha) – los municipios de alta vulnerabilidad muestran tiempos de resolución consistentemente más largos en todo el horizonte temporal.




Fig. 4. Modelo de riesgos proporcionales de Cox: hazard ratios para la duración del caso. Las variables con $HR < 1$ (ej., IVF más alto, más audiencias) prolongan la duración del caso. La concordancia de 0.874 indica un fuerte poder discriminativo.

5.6 El Tablero

El tablero Streamlit proporciona una interfaz intuitiva. Los usuarios filtran por municipio, año y tipo de proceso; visualizan mapas de IVF; inspeccionan alertas tempranas; predicen la duración de nuevos casos; y comparan el rendimiento de los juzgados. El predictor utiliza el modelo XGBoost serializado en tiempo de ejecución, con un respaldo heurístico cuando el modelo no está disponible.

5.7 Limitaciones

1. **Datos sintéticos.** Todos los resultados se basan en registros generados. Se necesitan datos reales del CSJ para su validación.

2. **Brecha de MAPE.** El MAPE del 16.0% está a 1 punto porcentual del objetivo; el ajuste de hiperparámetros y los datos reales deberían cerrar esta brecha.
3. **Cobertura parcial de fuentes.** Solo 4 de 6 fuentes de datos estuvieron completamente disponibles. Los datos de la Policía SIEDCO no arrojaron resultados para el Valle del Cauca.
4. **Granularidad geográfica.** El análisis es a nivel municipal; no se capturan las dinámicas a nivel de barrio.

6 Conclusiones

LexData demuestra que el aprendizaje automático puede extraer patrones significativos de los datos de procesos judiciales incluso con restricciones de datos. Nuestro modelo XGBoost explica el 86.9% de la varianza de la duración, y el sistema de alertas tempranas identifica el 22.8% de los casos como en riesgo. Dos hallazgos destacan:

1. Las apelaciones y el número de audiencias dominan la predicción de la duración, representando el 87% de la importancia de las variables. Las intervenciones de gestión judicial dirigidas a estos factores – como la resolución alternativa de conflictos para casos con probabilidad de apelación – podrían tener un impacto desproporcionado.
2. El Índice de Vulnerabilidad Familiar, aunque no es un predictor fuerte a nivel de caso, proporciona información geográfica procesable. Los municipios con IVF superior a 62 (el percentil 75) muestran consistentemente duraciones más largas, lo que respalda la asignación selectiva de recursos.

El código y la documentación de la plataforma son de código abierto. Invitamos a investigadores y operadores judiciales a adaptar, probar y extender LexData con registros judiciales reales.

Trabajo Futuro

Las extensiones planificadas incluyen: (1) integración de datos reales de casos del sistema SIAU del CSJ, (2) modelos especializados por tipo de proceso (VIF, alimentos, custodia), (3) despliegue del análisis de supervivencia en el tablero para probabilidad de resolución en tiempo real, (4) expansión geográfica a Bogotá, Medellín y Barranquilla, y (5) evaluación formal con actores judiciales.

Acknowledgments. Esta investigación se realizó como parte del curso Data Thinking (2025–1) en la Universidad Autónoma de Occidente. Agradecemos al profesor Juan Manuel Núñez por su orientación.

References

1. de la Judicatura, C.S.: Estadísticas de gestión judicial 2023 (2023), dirección Ejecutiva de Administración Judicial. <https://www.ramajudicial.gov.co>
2. de Bienestar Familiar, I.C.: Informe de gestión: medidas de protección a la familia 2023 (2023), <https://www.icbf.gov.co>
3. de la República de Colombia, C.: Ley 2126 de 2021: Comisarías de familia (2021)
4. Chen, T., Guestrin, C.: Xgboost: A scalable tree boosting system. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining pp. 785–794 (2016)
5. Katz, D.M., Bommarito, M.J., Blackman, J.: A general approach for predicting the behavior of the supreme court of the united states. PLOS ONE **12**(4), e0174698 (2017)
6. Medvedeva, M., Vols, M., Wieling, M.: Machine learning and the prediction of judicial decisions: A survey. Computer Law & Security Review **36**, 105384 (2020)
7. González, F., Oliveira, R.: Predicting labor court case duration using gradient boosting in brazil. Journal of Empirical Legal Studies **19**(3), 712–741 (2022)
8. Pérez, A., Gómez, C.: Clasificación automática de tipos de proceso judicial en colombia usando procesamiento de lenguaje natural. Revista de Derecho y Tecnología **15**(2), 88–112 (2023)
9. Flores, A., Smith, T.: Social vulnerability and community resilience: A review. Annual Review of Public Health **41**, 381–396 (2020)
10. Shaw, C.R., McKay, H.D.: Juvenile delinquency and urban areas. University of Chicago Press (1942)
11. Wang, J., Liu, H., Chen, Y.: Crime hotspot prediction using gradient boosting and socioeconomic variables. Computers, Environment and Urban Systems **93**, 101755 (2022)
12. Spohn, C.: Thirty years of sentencing reform: The quest for a racially neutral sentencing process. Criminal Justice **3**, 427–501 (2002)
13. Ulmer, J.T.: Trial court delay and the problem of formal rationality: A comparative perspective. Justice Quarterly **35**(3), 421–449 (2018)
14. Davidson-Pilon, C.: lifelines: survival analysis in python. Journal of Open Source Software **4**(40), 1317 (2019)